

Recherche en sécurité de l'IA



**ALIGNER
LES OBJECTIFS**




**RENDRE ROBUSTE
AUX ERREURS**



**COMPRENDRE
LE FONCTIONNEMENT**



**DÉTECTER
LES BIAIS**



SYSTÈME D'IA

34

LOT **5**



Recherche en sécurité de l'IA

Ensemble de travaux visant à rendre les systèmes d'IA fiables et contrôlables : mieux aligner leurs objectifs sur les nôtres, les rendre robustes aux erreurs, comprendre leur fonctionnement, détecter leurs biais. Ces recherches disposent de beaucoup moins de moyens et avancent bien moins vite que les capacités des IA.

34

LOT

5

