


Risques de mésalignement



CE QUE L'IA FAIT
comportement imprévu, indésirable

22

CAPACITÉS DE L'IA

LOT 3



Risques de mésalignement

Une IA est dite « alignée » quand elle fait réellement ce que ses concepteur·ices veulent qu'elle fasse : poursuivre leurs objectifs, selon leurs valeurs et leurs intentions. Une IA mésalignée a donc des comportements imprévus et/ou indésirables. L'augmentation des capacités des modèles amplifie grandement les conséquences d'un mésalignement.



LOT

3

